3、编程作业：基于 Transformer 的 NER

3.1 作业内容

一、语料:

1、训练语料:

train.txt 为字(符号)序列，train_TAG.txt 为对应 train.txt 中每一个字(符号)的实体标签。例如，在 train.txt 中的第一句的字序列为：人 民 网 1 月 1 日 讯 据 《 纽 约 时 报 》报 道，而在 train_TAG.txt 中对位的标签序列为：O O O B_T I_T I_T I_T O O O B_LOC I_LOC O O O O O O 。即如下表:

train.txt 中的字(符号)	train_TAG.txt 中对位的标签	说明
人	O	非命名实体中的字(符号)
民	O	非命名实体中的字(符号)
网	O	非命名实体中的字(符号)
1	B_T	时间实体的开头字
月	I_T	时间实体的中间字
1	I_T	时间实体的中间字
日	I_T	时间实体的中间字
讯	O	非命名实体中的字(符号)
据	O	非命名实体中的字(符号)
《	O	非命名实体中的字(符号)
纽	B_LOC	地点实体的开头字
约	I_LOC	地点实体的中间字
时	O	非命名实体中的字(符号)
报	O	非命名实体中的字(符号)
》	O	非命名实体中的字(符号)
报	O	非命名实体中的字(符号)
道	O	非命名实体中的字(符号)
,	O	非命名实体中的字(符号)
……	……	……

2 发展集 dev.txt 及其标注 dev_TAG.txt（标注规范和 train_TAG.txt 中的相同），可用于训练过程中进行模型选择。

3 测试语料：test.txt：用于测试模型。

4 结果输出:

基于 train.txt 和 train_TAG.txt 数据训练一个以 Transformer 为基础结构的命名实体识别模型，进而为 test.txt 进行序列标注，输出标签文件，标签文件输出格式与 train_TAG.txt 相同。即保持 test.txt 中的行次序、分行信息以及行内次序，行内每个字的标签之间用空格分隔。输出文件命名方式：学号.txt。

二、关于模型设计：

模型必须以 Transformer 为基础结构，可以单独采用 Transformer 编码器(典型的如 BERT)，也可以单独采用 Transformer 解码器(典型的如 GPT)，或者编码器+解码器的组合(典型的如 T5)。Transformer 的层数等超参数自选，字向量可以随机初始化后训练，也可以采用已有开放词向量作为初始值，维度自选。是否采用类 CRF 模块建模序标关联可选。

三、所有输出文本均采用 Unicode(UTF-8)编码、算法采用 Python (3.0 以上版本) 实现

四、此次作业需要提交的材料

1、说明文档：

基于 Transformer 结构的序标模型和训练算法的文本说明，提交 doc(或 pdf)文件，文件命名方式：学号；文本说明至少包括：

a)给出标注集(标签集)。序列标注的标签集是 train_TAG.txt 中的所有不同的标签组成的集合，请自行统计获得，标签集是后续训练模型和标注的基础，请注意统计完整。

b)对模型和执行细节进行说明。模型和执行细节应至少包含：模型的结构及其结构参数(如用什么 transformer、堆叠层数、输入 token 数等等)、所用初始字向量的来源、向量维数、训练算法以及学习率、训练批次大小、训练轮数等；

c)给出训练损失和发展集性能随时间变化的曲线：每轮记录训练 loss，同时每一轮在发展集上进行测试，获得其标注性能(准确率)。给出所选择用来进行测试的训练轮次。

d)参考文献。给出参考的论文、网站、代码链接等等，说明是否使用了大模型辅助，辅助程度如何。

2、代码：

提交完整的实现代码，其中关键部分需要进行注释说明：与文本说明中的参数和执行细节对应。

3、结果：

对 test.txt 进行序列标注得到的标注文件。提交 txt 文件，文件命名方式：学号.txt；

3.2 分数分配

评分时以上面要求提交的材料为依据进行，其中说明文档占 40 分、代码占 30 分、结果占 30 分。具体说明如下(按总数为 100 分进行说明)：

一、说明文档（40分）

1、数据加工

给出标注集(标签集)。序列标注的标签集是train_TAG.txt 中所有不同的标签组成的集合，请自行统计获得，标签集是后续训练模型和标注的基础，请注意统计完整。

评分细则：总分6 分。给出完整的标注集5 分，说明了通过什么函数获得标注集、统计次数或有标注集到索引数的对应加1 分。

2、基于代码的模型说明和执行细节进行说明

模型实现和执行细节应至少包含：执行模型的代码结构说明、模型结构参数(如用什么transformer、代码怎么实现的、堆叠层数、输入token数、所用初始字向量的来源、向量维数、训练算法以及学习率、训练批次大小、训练轮数等等。

评分细则(总分20 分)：

模型执行的深入程度会影响起评分，不同深入程度举例：

- 浅：直接调高层库；(起评分 10 分)
- 一般：在较小单元结构下的函数调用，包括数据处理和模型结构的分解；(起评分 12 分)
- 深入：自己写了更多的数据处理细节、训练细节、额外的效率考虑等(都请在文档中进行详细说明)。(起评分 14 分)

需要说明的其他信息：模型的结构及其结构参数(如用什么transformer、堆叠层数、输入token 数等等)，所用初始字向量的来源、向量维数、训练算法、学习率、训练批次大小、训练轮数，还可以补充其他执行细节。在起评分基础上加满至20分。

如果存在说明和实际代码不相符的情况，则对应部分的分数均为0分。

3、给出训练损失和发展集性能随时间变化的曲线

记录每轮训练loss，同时每一轮在发展集上进行测试，获得其标注性能(准确率)，绘制成曲线。基于此选择模型参数。

评分细则：总分8分。训练损失曲线、发展集性能曲线各3分，选择2分。

4、参考文献

给出参考的论文、网站、代码链接等等，说明是否使用了大模型辅助，辅助程度如何。

评分细则：总分6分。参考文献3分、大模型辅助程度说明3分，按详细程度酌情加1-2 分。

二、实现代码（30%）

模型实现使用代码的深入程度会影响起评分，不同深入程度举例：

- 浅：直接调高层库；(起评分 12 分)
- 一般：在较小单元结构下的函数调用，包括数据处理和模型结构的分解；(起评分 15 分)
- 深入：自己写了更多的数据处理细节、训练细节、额外的效率考虑等(都请在文档中进行详细说明)。(起评分 18 分)

在此基础上考虑代码写作：注释规范、详细，最多加至12分。

如果代码存在关键性错误，不可运行，则无起评分。

三、结果（30%）

评分细则：30分。依据结果与参考答案进行对比，输出百分制准确率，之后总分30分转换(准确率100%=30分，准确率0=0分)，采取四舍五入制。

3.3 其他说明

可以参考已有代码或使用大模型辅助，但是不允许直接使用已有代码，也不允许使用大模型直接写的代码。请在文档中明确说明在编程过程的参考材料(包括网页、文献等)，以及使用了什么大模型、使用大模型的具体程度情况。